



République Tunisienne
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université de Sfax
Faculté des Sciences de Sfax (FSS)



TP4 : Rapport Project "Pneumonia classification"

Préparé par :

Belguith Ahmed Rami

Koubaa Mahdi

Année universitaire : 2023-2024

Contents

1. Introduction	3
2. Chargement et Prétraitement de Données	3
3. Proposition de Modèles	4
○ Un modèle développé à partir de zéro	4
○ Un modèle exploitant l'architecture ResNet.....	4
○ Trois modèles basés sur l'architecture VGG16.....	4
4. Entraînement des Modèles.....	5
5. Évaluation des Performances.....	6
○ Modèle à partir de zéro :	6
○ Modèle du ResNet :	7
○ Modèle du VGG16 (RMSprop):	7
○ Modèle du VGG16 (Adam):	8
○ Modèle du VGG16 (Adam Avec CNN gèle):	9
6. Comparaison des Modèles.....	10
7. Rapport	11

1. Introduction

- Le projet vise à développer un modèle de deep learning dédié à la classification d'images de radiographies thoraciques (chest X-ray) pour la détection de la pneumonie. La base de données disponible pour ce projet est constituée de deux classes distinctes : "normal" et "Pneumonia". Cependant, un défi majeur se présente en raison du déséquilibre notable au sein de la base de données d'entraînement. En effet, la classe "normal" compte 1 341 images de radiographies, tandis que la classe "Pneumonia" en compte 3 875. Cette disparité de taille entre les deux classes peut rendre l'apprentissage du modèle plus complexe, car il peut avoir tendance à privilégier la classe majoritaire.
- La base de données est répartie en trois ensembles distincts : l'ensemble d'entraînement (train), l'ensemble de validation (val) et l'ensemble de test. L'objectif principal est d'entraîner un modèle capable de généraliser efficacement sur de nouvelles données et de détecter avec précision la présence de pneumonie dans les radiographies thoraciques.
- Le déséquilibre des classes soulève des questions importantes quant à la performance potentielle du modèle, et des stratégies spécifiques devront être mises en œuvre pour atténuer cet impact, telles que l'utilisation de techniques de suréchantillonnage, de sous-échantillonnage ou d'autres méthodes de gestion des classes déséquilibrées.

2. Chargement et Prétraitement de Données

- Le chargement et le prétraitement des données jouent un rôle crucial dans le développement d'un modèle de deep learning robuste pour la classification d'images de radiographies thoraciques. Dans le projet, nous observons la mise en place d'un pipeline de chargement de données utilisant la classe ImageDataGenerator de Keras. Cette classe offre des fonctionnalités d'augmentation de données pour le jeu d'entraînement, telles que la rotation, le décalage en largeur et en hauteur, le cisaillement, le zoom et le retournement horizontal.
- Le réglage de l'échelle des valeurs de pixels avec $\text{rescale}=1./255$ normalise les intensités des pixels entre 0 et 1, facilitant ainsi la convergence du modèle lors de l'entraînement.
- Les générateurs de données, `train_generator` et `validation_generator`, sont créés pour alimenter le modèle en lots de données lors de l'entraînement et de la validation,

respectivement. La taille des lots (batch_size) est définie à 64, mais peut être ajustée en

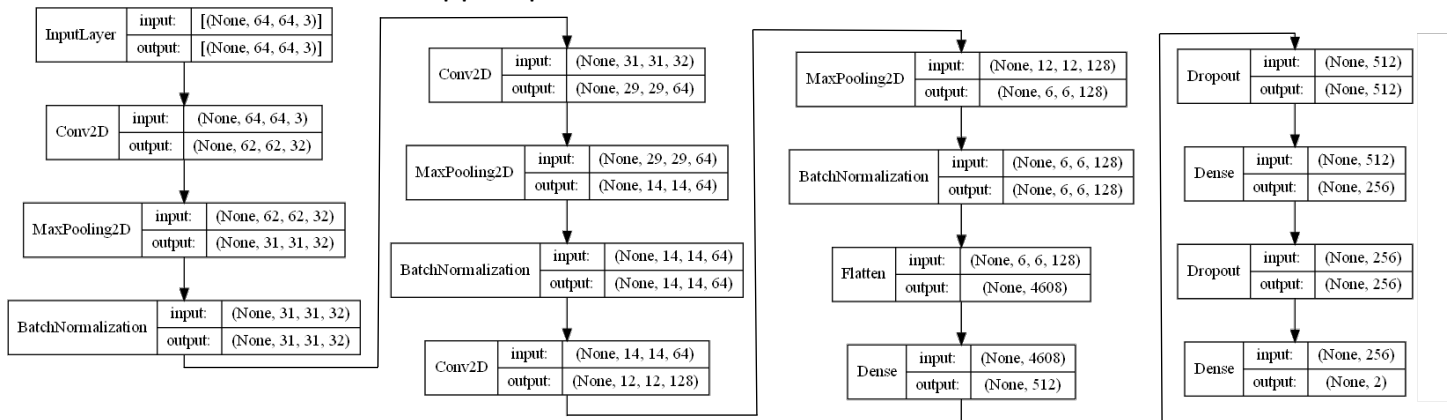
fonction des ressources matérielles disponibles. Les générateurs utilisent le mode de classe 'categorical', indiquant que les étiquettes sont encodées de manière catégorique pour représenter les classes "normal" et "Pneumonia".

3. Proposition de Modèles

Pour répondre aux exigences de ce projet de classification d'images de radiographies thoraciques pour la détection de la pneumonie, nous avons envisagé plusieurs approches de modélisation :


- Un modèle développé à partir de zéro

Architecture du modèle développé a partir de zéro :



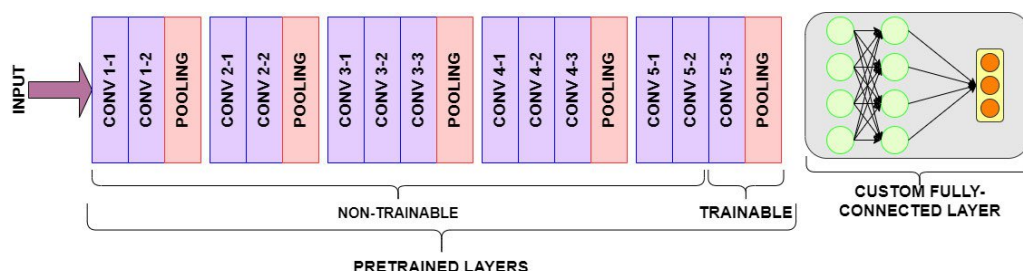
- Un modèle exploitant l'architecture ResNet

Architecture du modèle ResNet



- Trois modèles basés sur l'architecture VGG16

Architecture du modèle VGG16



4. Entraînement des Modèles


Pour l'entraînement des modèles, un point de contrôle a été utilisé pour surveiller la précision et sauvegarder uniquement le meilleur, ainsi qu'un arrêt anticipé pour surveiller la précision avec une patience de 20 et une fonction de perte catégorielle pour chaque modèle.

- Pour le modèle créé à partir de zéro, l'optimiseur RMSProp avec un taux d'apprentissage de 0,0001 et 100 époques ont été utilisés. L'arrêt anticipé s'est déclenché à l'époque 67.
- Pour le modèle utilisant le transfert d'apprentissage ResNet, l'optimiseur Adam avec un taux d'apprentissage de 0,00001 et 100 époques ont été utilisés. Les couches supérieures n'ont pas été incluses, et les 5 premières couches du CNN ont été gelées.
- Pour le premier modèle utilisant le transfert d'apprentissage VGG16, l'optimiseur RMSProp avec un taux d'apprentissage de 0,0001 et 100 époques ont été utilisés. Les couches supérieures n'ont pas été incluses, et les 5 premières couches du CNN ont été gelées. L'arrêt anticipé s'est déclenché à l'époque 50.
- Pour le deuxième modèle utilisant le transfert d'apprentissage VGG16, l'optimiseur Adam avec un taux d'apprentissage de 0,00001 et 100 époques ont été utilisés. Les couches supérieures n'ont pas été incluses, et les 5 premières couches du CNN ont été gelées. L'arrêt anticipé s'est déclenché à l'époque 80.
- Pour le troisième modèle utilisant le transfert d'apprentissage VGG16, l'optimiseur Adam avec un taux d'apprentissage de 0,00001 et 100 époques ont été utilisés. Aucune couche supérieure n'a été incluse, et toutes les couches du CNN ont été gelées.

5. Évaluation des Performances


On a des graphiques qui affichent l'exactitude et la perte du modèle pendant l'entraînement et la validation.

- Modèle à partir de zéro :




- Époques 0 à 10 : Augmentation rapide de l'exactitude de 0,5 à environ 0,7, avec une diminution rapide de la perte de 1 à environ 0,5.
- Époques 10 à 30 : Augmentation continue mais lente de l'exactitude jusqu'à environ 0,8, avec une diminution continue mais lente de la perte jusqu'à environ 0,2.
- Époques 30 à 40 : Plateau de l'exactitude à environ 0,9, avec une légère diminution continue de la perte jusqu'à environ 0,1.
- Époques 40 à 67 : Amélioration continue à un rythme lent mais stable, l'exactitude reste à environ 0,9, avec une légère diminution continue de la perte. Suggère un plateau de performance, mais la possibilité d'une légère amélioration persiste.

○ Modèle du ResNet :




- Époques 0 à 20 : Augmentation rapide de l'exactitude du modèle de 0,5 à 0,9, avec une diminution rapide de la perte de 0,5 à 0,1. Amélioration rapide due à l'apprentissage rapide des relations entre les données d'entraînement.
- Époques 20 à 40 : Stabilisation de la performance du modèle au cours des 20 époques suivantes. L'exactitude reste autour de 0,9, et la perte reste autour de 0,1. Indique que le modèle a appris la majeure partie de ce qu'il peut apprendre sur les données d'entraînement.
- Époques 40 à 100 : Aucun changement significatif dans la performance du modèle au cours des 60 époques suivantes. L'exactitude persiste autour de 0,9, et la perte reste autour de 0,1.

○ Modèle du VGG16 (RMSProp):





- Époques 0-10 : Augmentation rapide de la précision du modèle de 0,5 à environ 90 %, avec une diminution rapide de la perte de 1 à environ 0,5. Indique que le modèle commence à apprendre des caractéristiques importantes des données.
- Époques 10-20 : Continuation de l'augmentation de la précision à environ 95 %, avec une diminution continue de la perte à environ 0,2. Suggère que le modèle continue à apprendre et à s'améliorer.
- Époques 20-50 : Stabilisation de la précision du modèle à environ 95 % au cours de ces époques, avec une stabilisation correspondante de la perte à environ 0,2.

○ Modèle du VGG16 (Adam):



- Époques 0 à 20 : Augmentation rapide de la précision du modèle de 0,6 à 0,8, avec une diminution rapide de la perte de 0,5 à 0,2. Indique un apprentissage rapide des caractéristiques importantes des données de validation.
- Époques 20 à 50 : Poursuite de l'augmentation de la précision, mais à un rythme plus lent, atteignant un niveau plus élevé. La perte du modèle diminue également, mais à un rythme plus lent, suggérant un apprentissage des caractéristiques plus subtiles des données de validation.
- Époques 50 à 80 : Plateau de la précision du modèle à environ 0,95 au cours de ces 30 époques, avec une perte du modèle stabilisée à environ 0,1. Indique que le modèle a atteint un plateau de performance, ayant appris la plupart des caractéristiques des données de validation.

○ Modèle du VGG16 (Adam Avec CNN gèle) :



- Époques 1 à 20 : Début de l'entraînement, le modèle apprend les bases des données avec une précision et une perte relativement faible.
- Époques 20 à 40 : Apprentissage des relations complexes entre les données, avec augmentation de la précision et de la perte.
- Époques 40 à 60 : Poursuite de l'apprentissage et amélioration de la précision, accompagnées d'une diminution continue de la perte.
- Époques 60 à 80 : Atteinte de la précision maximale, avec une diminution continue de la perte.
- Époques 80 à 100 : Début du surapprentissage des données d'entraînement, légère diminution de la précision, mais la perte continue de diminuer.

6. Comparaison des Modèles

Pour comparer les modèles, nous avons mis en place un système pour effectuer des prédictions avec le modèle sur l'ensemble de test. Ensuite, nous avons calculé l'exactitude (accuracy) pour la classe 1 (normale) et l'exactitude pour la classe 2 (pneumonie).

Modèle	From Scratch	ResNet	VGG16 (Adam)	VGG16 (RMSProp)	VGG16 (Gelée)
Accuracy Class1	94.017%	49.145%	58.119%	69.230%	80.769%
Accuracy Class2	53.589%	98.717%	99.230%	98.974%	91.538%

1. From Scratch:

- Précision Class1 : 94.017% - Une excellente précision pour la Class1, indiquant que le modèle est capable de bien distinguer les exemples de la Class1.
- Précision Class2 : 53.589% - Une précision relativement faible pour la Class2, suggérant que le modèle a du mal à généraliser et à reconnaître les exemples de la Class2.

2. ResNet:

- Précision Class1 : 49.145% - Une précision relativement faible pour la Class1, indiquant des difficultés à identifier correctement les exemples de cette classe.
- Précision Class2 : 98.717% - Une excellente précision pour la Class2, montrant que le modèle excelle dans la reconnaissance des exemples de la Class2.

3. VGG16 (Adam):

- Précision Class1 : 58.119% - Une amélioration par rapport à ResNet pour la Class1, mais encore relativement modérée.
- Précision Class2 : 99.230% - La meilleure précision globale pour la Class2 parmi tous les modèles, indiquant une capacité exceptionnelle à reconnaître les exemples de cette classe.

4. VGG16 (RMSPProp):

- Précision Class1 : 69.230% - Une nette amélioration par rapport à ResNet et VGG16 (Adam) pour la Class1.
- Précision Class2 : 98.974% - Une précision élevée pour la Class2, bien que légèrement inférieure à VGG16 (Adam).

5. VGG16 (Gelée):

- Précision Class1 : 80.769% - La meilleure précision pour la Class1 parmi tous les modèles, montrant une excellente capacité à distinguer les exemples de cette classe.
- Précision Class2 : 91.538% - Bien que légèrement inférieure à VGG16 (Adam), la précision pour la Class2 reste élevée.

En conclusion, le modèle VGG16 avec l'optimiseur Gelée affiche des performances exceptionnelles dans cette comparaison grâce à l'utilisation judicieuse d'une base pré-entraînée. Cette approche présente plusieurs avantages clés :

- Transfert de Connaissances : La partie pré-entraînée de VGG16, formée sur un ensemble de données diversifié, capture des représentations générales des images, préservant ces connaissances sans altération pendant l'entraînement sur des données spécifiques.
- Évitement du Surajustement : En figeant la partie pré-entraînée, le modèle évite le risque de surajustement aux données d'entraînement actuelles, favorisant une meilleure généralisation sur de nouvelles données, surtout en cas de données d'entraînement limitées.
- Économie de Temps et de Ressources : En gelant la partie convolutive, on réduit le temps et les ressources nécessaires pour entraîner une architecture complexe comme VGG16 à partir de zéro, tout en profitant des avantages des caractéristiques pré-entraînées.

7. Rapport

Le projet vise à développer des modèles de classification d'images de radiographies thoraciques pour détecter la présence de pneumonie

Dans cette étude comparative, cinq approches distinctes ont été évaluées pour résoudre ce problème. La première approche, consistant en un modèle créé à partir de zéro, a démontré une précision notable de 94.017% pour la classe 1, mais a affiché une performance relativement modeste de 53.589% pour la classe 2, suggérant un potentiel surajustement.

La deuxième approche, basée sur le transfert d'apprentissage avec ResNet, a produit des résultats inattendus avec une précision élevée de 98.717% pour la classe 2, bien que la précision pour la classe 1 ait chuté à 49.145%. Cette disparité peut nécessiter une exploration plus approfondie des spécificités de l'architecture ResNet pour ce problème particulier.

Les troisième et quatrième approche ont utilisé le transfert d'apprentissage avec VGG16, variant l'optimiseur entre Adam et RMSProp. La troisième approche avec Adam a affiché une précision robuste de 58.119% pour la classe 1 et 99.230% pour la classe 2, avec un arrêt anticipé à l'époque 80. La quatrième approche, avec RMSProp, a amélioré la précision pour la classe 1 (69.230%) tout en conservant une excellente précision pour la classe 2 (98.974%), bien que l'arrêt anticipé à l'époque 50 puisse signaler une convergence plus rapide.

Enfin, la cinquième approche a gelé toutes les couches de VGG16, montrant une performance équilibrée avec une précision de 80.769% pour la classe 1 et 91.538% pour la classe 2. Cette approche a illustré l'efficacité du gel de toutes les couches pour préserver les caractéristiques apprises tout en s'adaptant au nouveau problème.

Efficacité du Transfert d'Apprentissage :

Le transfert d'apprentissage s'est avéré essentiel pour la classification des radiographies thoraciques, démontrant une performance nettement supérieure au modèle à partir de zéro. La complexité de la tâche découle de la similitude élevée entre les images et la difficulté à les comparer précisément, en raison des caractéristiques subtiles et des variations minimales entre les classes.

Cette approche capitalise sur les connaissances préalablement acquises par des modèles pré-entraînés sur des ensembles de données massifs et diversifiés. Ces modèles, initialement formés sur des images provenant de diverses sources, peuvent apprendre des caractéristiques générales et hautement abstraites.

Le transfert d'apprentissage adapte ces modèles pré-entraînés à la tâche spécifique de classification de radiographies thoraciques, exploitant ainsi leur capacité de généralisation même face à des images similaires et difficiles à distinguer. Cette méthode améliore significativement la précision de la classification en transférant la compréhension des motifs et des structures des tâches antérieures vers le problème actuel.

En outre, le transfert d'apprentissage offre un avantage temporel en utilisant le modèle pré-entraîné comme point de départ robuste, accélérant ainsi le processus d'apprentissage sur l'ensemble de données spécifique. Cette adaptation ciblée permet au modèle de se concentrer sur les caractéristiques pertinentes à la tâche, renforçant sa capacité à extraire des informations discriminantes des radiographies thoraciques.

Finalement, le transfert d'apprentissage émerge comme une stratégie essentielle et efficace pour aborder des tâches complexes de classification d'images médicales, particulièrement dans des domaines où la similarité des images représente un défi majeur.

Conclusion :

Les résultats mettent en lumière que l'approche de transfert d'apprentissage avec VGG16, en gelant les cinq premières couches, produit les meilleurs résultats, démontrant l'importance de la capacité de généralisation des caractéristiques extraites par les couches pré-entraînées. L'utilisation de l'optimiseur Adam semble plus efficace que RMSProp dans ce contexte. L'arrêt anticipé a été judicieusement utilisé pour éviter le surapprentissage, montrant son efficacité dans plusieurs approches. Cette conclusion souligne l'impact significatif du transfert d'apprentissage dans l'amélioration de la précision de la classification des radiographies thoraciques.